

Gaußsche Diskriminanzanalyse

Dr. rer. nat Dennis Müller

January 18, 2016

Table of Contents

Gaußsche
Diskriminan-
zanalyse

Dr. rer. nat
Dennis
Müller

Quadratische
Diskriminanz-
analyse

Gaußsche
Diskriminanz-
analyse

1 Quadratische Diskriminanzanalyse

2 Gaußsche Diskriminanzanalyse

Quadratische Diskriminanzanalyse - Merkmalsklassifikation

- Wir betrachten zunächst ein *Zwei-Klassen* Klassifikationsproblem.
- Dabei sei zu einem zu klassifizierenden Objekt ein n -dimensionaler *Featurevektor* $\mathbf{x}_i \in \mathbb{R}^n$ gegeben. Wir nehmen an dieser Vektor entstammt einer von zwei Klassen.
- Mit $y_i \in \{0, 1\}$ bezeichnen wir die Klasse des i -ten Featurevektors.
- Nach dem Satz von Bayes und dem Satz der totalen Wahrscheinlichkeit folgt dann

$$P(y_i|\mathbf{x}_i) = \frac{P(\mathbf{x}_i|y_i) \cdot p(y_i)}{P(\mathbf{x}_i|y_i = 0) \cdot p(y_i = 0) + P(\mathbf{x}_i|y_i = 1) \cdot p(y_i = 1)}$$

- In der Quadratische Diskriminanzanalyse gehen wir davon aus, dass die Featurevektoren innerhalb einer Klasse einer Normalverteilung entsprechen, also

$$P(\mathbf{x}_i|y_i) = \frac{1}{\sqrt{(2\pi)^n |\Sigma_{y_i}|}} \exp \left(-\frac{1}{2} (\mathbf{x}_i - \mu_{y_i})^T \Sigma_{y_i}^{-1} (\mathbf{x}_i - \mu_{y_i}) \right)$$

- Ferner nehmen wir an das die *a-priori* Wahrscheinlichkeit für die Klassenzugehörigkeit Bernoulli-verteilt ist, also

$$P(y_i) = \theta^{y_i} \cdot (1 - \theta)^{(1-y_i)}$$

mit $\theta \in [0, 1]$.

- Die Parameter unseres Modells sind also $\theta, \mu_0, \mu_1, \Sigma_0$ und Σ_1 .

- Angenommen wir haben ein Trainingsset von k Featurevektoren mit bekannter Klassenzugehörigkeit. Die *log-likelihood* der Daten ist dann

$$\begin{aligned}\lambda(\theta, \mu_0, \mu_1, \Sigma_0, \Sigma_1) &= \sum_{i=1}^k \log P(x_i, y_i | \theta, \mu_0, \mu_1, \Sigma_0, \Sigma_1) \\ &= \sum_{i=1}^k \log P(x_i | y_i, \mu_0, \mu_1, \Sigma_0, \Sigma_1) \cdot P(y_i | \theta)\end{aligned}$$

- Die *Maximum-likelihood* Schätzung für die fünf Parameter ergibt sich dann zu

$$\theta = \frac{1}{k} \sum_{i=1}^k y_i$$

$$\mu_0 = \frac{\sum_{i=1}^k x_i(1 - y_i)}{\sum_{i=1}^k (1 - y_i)}$$

$$\mu_1 = \frac{\sum_{i=1}^k x_i y_i}{\sum_{i=1}^k y_i}$$

$$\Sigma_0 = \frac{\sum_{i=1}^k (x_i - \mu_0)(x_i - \mu_0)^T (1 - y_i)}{\sum_{i=1}^k (1 - y_i)}$$

$$\Sigma_1 = \frac{\sum_{i=1}^k (x_i - \mu_1)(x_i - \mu_1)^T y_i}{\sum_{i=1}^k y_i}$$

- Sind die Parameter nun bekannt, z.B. durch obige ML-Schätzung, können wir einen neuen Featurevektor mit unbekannter Klassenzugehörigkeit *klassifizieren*. Dazu betrachten wir zunächst das Verhältnis der *a-posteriori* Wahrscheinlichkeiten

$$\frac{P(y_i = 1|\mathbf{x}_i)}{P(y_i = 0|\mathbf{x}_i)} = \frac{P(\mathbf{x}_i|y_i = 1)P(y_i = 1)}{P(\mathbf{x}_i|y_i = 0)P(y_i = 0)}$$

- Auch hier betrachten wir wieder den Logarithmus und erhalten zunächst

$$\log P(\mathbf{x}_i|y_i) = -\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma_{y_i}| - \frac{1}{2} (\mathbf{x}_i - \mu_{y_i})^T \Sigma_{y_i}^{-1} (\mathbf{x}_i - \mu_{y_i})$$

und

$$\log P(y_i) = y_i \log \theta + (1 - y_i) \log(1 - \theta)$$

- Nun gilt für den Logarithmus des Verhältnisses

$$\begin{aligned}
 g(\mathbf{x}_i) &= \log \frac{P(y_i=1|\mathbf{x}_i)}{P(y_i=0|\mathbf{x}_i)} \\
 &= \\
 &\quad -\frac{1}{2} \log |\Sigma_1| + \frac{1}{2} \log |\Sigma_0| \\
 &\quad -\frac{1}{2} (\mathbf{x}_i - \mu_0)^T \Sigma_0^{-1} (\mathbf{x}_i - \mu_0) + \frac{1}{2} (\mathbf{x}_i - \mu_1)^T \Sigma_1^{-1} (\mathbf{x}_i - \mu_1) \\
 &\quad + \log \left(\frac{\theta}{1-\theta} \right)
 \end{aligned}$$

- g heisst *Entscheidungsfunktion*.

- Der mittlere Term lässt sich schreiben als (aus-multiplizieren und neu zusammenfassen)

$$\begin{aligned} & \frac{1}{2} \mathbf{x}_i^T (\Sigma_1^{-1} - \Sigma_0^{-1}) \mathbf{x}_i \\ & + \\ & \mathbf{x}_i^T (\Sigma_0^{-1} \mu_0 - \Sigma_1^{-1} \mu_1) \\ & + \\ & \frac{1}{2} \mu_1^T \Sigma_1^{-1} \mu_1 - \frac{1}{2} \mu_0^T \Sigma_0^{-1} \mu_0 \end{aligned}$$

Gaußsche Diskriminanzanalyse - Spezialfall

- Bei der quadratischen Diskriminanzanalyse (QDA) gehen wir davon aus, dass beide Klassen unterschiedliche Varianzen haben können. Dadurch ergibt sich eine, i.d.R. quadratische *Grenzfläche* zwischen den beiden Klassen durch den Term

$$\mathbf{x}_i^T (\Sigma_1^{-1} - \Sigma_0^{-1}) \mathbf{x}_i$$

- Bei der Gaußschen Diskriminanzanalyse (GDA) nehmen wir an, dass beide Klassen *die gleiche* Varianz haben, also $\Sigma_0 = \Sigma_1 = \Sigma$. Dann ergibt sich für die ML Schätzung

$$\Sigma = \frac{1}{k} \sum_{i=1}^k (\mathbf{x}_i - \mu_{y_i})(\mathbf{x}_i - \mu_{y_i})^T$$

- Für die *Entscheidungsfunktion* folgt dann

$$g(\mathbf{x}_i) = \mathbf{x}_i^T \Sigma^{-1}(\mu_0 - \mu_1) + \frac{1}{2}(\mu_1 - \mu_0)^T \Sigma^{-1}(\mu_1 - \mu_0) + \log \left(\frac{\theta}{1 - \theta} \right)$$

- Hier ist die Entscheidungsfunktion also *linear* in \mathbf{x}_i .

- Für $\theta = 1/2$, also a-priori gleich wahrscheinliche Klassen ist $\log(\theta/(1 - \theta)) = 0$. Die Entscheidungsfunktion betrachtet dann nur die mit der (gleichen) Kovarianz gewichtete Distanz zwischen dem Featurevektor und beiden Klassenzentren. Die Zuordnung zu Klasse 1 erfolgt dann also g.d.w.

$$(\mathbf{x}_i - \mu_1)^T \Sigma^{-1} (\mathbf{x}_i - \mu_1) \leq (\mathbf{x}_i - \mu_0)^T \Sigma^{-1} (\mathbf{x}_i - \mu_0)$$

- Die so gewichtete Distanz bezeichnet man auch als *Mahalanobis*-Distanz.
- In diesem Spezialfall ist die GDA also ein Nearest-Neighbor Klassifikator.